

$$5.) a) LDL_i = \beta_0 + \beta_1 TCH_i + \beta_2 HDL_i + \beta_3 TRI_i + \varepsilon_i \quad \varepsilon_i \sim N(0, \sigma^2)$$

(i)  $\beta_0, \beta_1, \beta_2, \beta_3$  so MNK

Kemo:  $\hat{\beta} = (Z^T Z)^{-1} Z^T \vec{Y}$ , kjer je  $(Z^T Z)^{-1}$  razplošeni inverz

$$\text{Definiramo: } Z = \begin{bmatrix} 1 & TCH & HDL & TRI \\ \vdots & \vdots & \vdots & \vdots \\ 1 & TCH_n & HDL_n & TRI_n \end{bmatrix} \text{ in } \vec{Y} = \begin{bmatrix} LDL_1 \\ \vdots \\ LDL_n \end{bmatrix} \text{ in}$$

$\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3)$  izračunamo v R na kot:

$$- \hat{\beta} = (Z^T Z)^{-1} Z^T \vec{Y} \text{ (prek G-S algoritma)}$$

$$- \hat{\beta} = (Z^T Z)^{-1} Z^T \vec{Y} \text{ (z različnim inverzom)}$$

-  $Z$  uporabo funkcije `lm` vgrajene v R

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$

Na vseh treh metodah dobimo enak rezultat za ocene in raven:

$$\hat{\beta}_0 = 0.3773332 \quad \hat{\beta}_1 = 0.8534945 \quad \hat{\beta}_2 = -0.8311743 \quad \hat{\beta}_3 = -0.2738845$$

(ii)  $H_0: \beta_1 = \beta_2 = \beta_3 = 0$  na standarden način pri  $\alpha = 0.05$

1. način: postopamo kot pri Ekonometriji 1: Najprej razpišemo oba modela

$$\text{Unrestricted model: } LDL_i = \beta_0 + \beta_1 TCH_i + \beta_2 HDL_i + \beta_3 TRI_i + \varepsilon_i$$

$$\text{Restricted model: } LDL_i = \beta_0 + \varepsilon_i$$

Za vsak model moramo poračunati vsoto kvadratov residualov:

$$VKR = \sum_{i=1}^n (\hat{\varepsilon}_i)^2 = \sum_{i=1}^n (Y_i - (\hat{\beta}_0 + \hat{\beta} X_i))^2$$

Primer to pomeni:

$$- \text{VKR za unrestricted model: } VKR_U = \sum_{i=1}^{300} (LDL_i - \hat{\beta} Z_i)^2, \text{ kjer sta } \beta \text{ in } Z \text{ kot v (i)}$$

$$- \text{VKR za restricted model: } VKR_R = \sum_{i=1}^{300} (LDL_i - \hat{\beta}_0)^2$$

Testiramo z F testom:

$$F = \frac{(VKR_R - VKR_U) / (r_u - r_R)}{VKR_U / (n - r_U)}$$

$$\text{test} = \begin{cases} H_0 \text{ zavrnemo; } F > F_{2, n-k_4; \alpha} \\ H_0 \text{ ne zavrnemo; raven} \end{cases}$$

Tu je  $q = r_u - r_R$ , kjer sta  $r_u$  in  $r_R$  števili prostostnih stopenj v unrestricted in restricted modelu.  $q$  je torej število restrikcij, omejitev.  $n = 300$

$F_{2, n-r_U; \alpha}$  je vrednost F-razporeditve za restrikcijami modela in  $\alpha = 0.05$

Poračunamo v R in dobimo:

$$F = 426.1932 > 2.6351 = F_{3, 246; 0.05}$$

torej ničelno hipotezo zavrnemo.



## 2. način:

$H_0$  zapisemo v matrični obliki:  $H_0: L\beta = c$ . Da dobimo našo hipotezo moramo ujeti:

$$L = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \text{ in } c = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

testna statistika je tu:

$$F = \frac{(L\beta - c)^T [L(Z^T Z)^{-1} L^T]^{-1} (L\beta - c)}{VKR / (n-d)}$$

test je enak kot v prvem načinu

Poračunamo  $VR$  in dobimo:  $F = 426 > 2.6351 = F_{3,296;0.05}$

Tudi po tem načinu  $H_0$  ne zavrnemo.

namo pri stolpec matrike  $Z$ :  $\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \Rightarrow \beta = (Z^T Z)^{-1} Z^T X$   
 $Z^T Z = [1 \dots 1] \cdot \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = n = n^{-1} \cdot [1 \dots 1] X = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$

## 3. način: (z STAT1 vemo)

Poravnemo ocene  $\hat{\beta}_{H_0} = \begin{bmatrix} \bar{X} \\ 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} \overline{LDL} \\ 0 \\ 0 \\ 0 \end{bmatrix}$

in število stopnje svobode  $r=3$

?

Vemo:  $F(x) = \frac{\|Z\hat{\beta}(x) - Z\hat{\beta}_{H_0}(x)\|^2 / r}{VKR(x) / (n-d)} \sim F_{r, n-d; \alpha}$  (test torej enak kot v prejšnjih 2 načinih)

$VKR(x) = \|X - Z\hat{\beta}(x)\|^2$ ,  $\hat{\beta}(x)$  je vektor  $\beta$ , s komponentami ocenjenimi v a) (i).

Ustavimo  $VR$ , poračunamo in tudi tu dobimo:  $F = 426 > 2.6351 = F_{3,296;0.05}$

(iii) Preizkusite  $H_0: \beta_0 = 0$  na standarden način

## 1. način:

Če računamo  $ZR$  v lm(...) modelu,  $R$  nam poračuna  $t$ -statistiko.

Moramo le še primerjati s testom:  $\begin{cases} H_0 \text{ zavrnemo; } |t| > t_{n-d; \alpha} \\ H_0 \text{ ne zavrnemo; } \text{icer} \end{cases}$

Čer je  $t_{n-d, \alpha/2}$  studentova porazdelitev. Poračunamo vrednosti  $VR$  in dobimo:

$|t| = 1.92036 < 1.9680 = t_{296;0.025}$ , torej  $H_0$  ne zavrnemo.

## 2. način:

Uporabimo enak postopek kot v 2. načinu (ii) Focke (Fisher delodeluje tudi za 1 parameter).

Ustavimo  $L = [1 \ 0 \ 0 \ 0]$  in  $c = 0$ , poračunamo  $VR$  in dobimo

~~$F = 3.6878$~~   $F = 3.6878 < 3.8731 = F_{1,296;0.05}$  torej  $H_0$  ne zavrnemo

3. način: Vrnemo se nazaj k studentu iz 1. načina (vzamemo enak preizkus)

Definiramo  $t(x) = \frac{c\hat{\beta}(x), V}{\sqrt{c(Z^T Z)^{-1} V, V} \cdot \sqrt{\frac{VKR}{n-d}}}$ , kjer je  $V = (1, 0, 0, 0)$  (vektor)

Poračunamo  $VR$  in dobimo:  $|t(x)| = 1.92036 < 1.9680 = t_{296;0.025}$ , torej  $H_0$  ne zavrnemo.

(po STAT 1)

$$b) LDL_i = \beta_1 \cdot TCH_i + \beta_2 \cdot HDL_i + \beta_3 \cdot TRI_i + \epsilon_i$$

(i)  $\beta_1, \beta_2, \beta_3$  so MNK

Postopamo identično kot v a) (i), le brez prostega člena.

Spet po vseh treh metodah dobimo enak rezultat in sicer:

$$\beta_1 = 0.8954892 \quad \beta_2 = -0.7956929 \quad \beta_3 = -0.2563894$$

(ii) ~~MNPK~~  $H_0: (\beta_1, \beta_2, \beta_3) = (1, -1, -0.45)$

1. način iz a) (ii)  $\rightarrow$  ne bo primeren

2. način iz a) (ii):

Čepišemo  $H_0: L\beta = c$ , kjer vzamemo  $L = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$  in  $c = \begin{bmatrix} 1 \\ -1 \\ -0.45 \end{bmatrix}$   $n=300$   
 $d=3$

Kot v a) (ii) poračunamo

$$F = \frac{(L\beta - c)^T [L \cdot (Z^T Z)^{-1} L^T]^{-1} (L\beta - c)}{VKR / (n-d)}$$

$$\text{test} = \begin{cases} H_0 \text{ zavrnemo; } F > F_{\alpha, n-d; d} \\ H_0 \text{ ne zavrnemo; sicer} \end{cases}$$

Poračunamo v R in dobimo:  $F = 20.4 > 2.6350 = F_{3, 297; 0.05}$

$\Rightarrow$  Hipotezo  $H_0$  torej zavrnemo.

3. način iz a) (ii):

Poračunamo oceno  $\hat{\beta}_H = \begin{bmatrix} 1 \\ -1 \\ -0.45 \end{bmatrix}$  in iterilo omejitev  $\Rightarrow$

$$\text{Umo: } F(x) = \frac{\|Z\hat{\beta}(x) - Z\hat{\beta}_H(x)\|^2}{VKR(x) / (n-d)} \sim F_{r, n-d; \alpha}$$

Test je seveda enak kot v prejšnjem načinu.

Poračunamo:  $VKR(x) = \|x - Z\hat{\beta}(x)\|^2$

Vstavimo v R, izračunamo in dobimo

$$F = 20.4 > 2.6350 = F_{3, 297; 0.05}$$

$\Rightarrow$  seveda tudi po tem načinu ~~nizelno~~ ~~hipotezo~~ zavrnemo.

$H_0$



(iii) Območje razpaja za  $(\beta_1, \beta_2, \beta_3)$  st. razpaja 0.95

Izotopamo kot na predavanjih:

$$\text{Imamo } X \sim N(\tau\beta, \sigma^2 I) \quad (X = \tau\beta + \varepsilon, \varepsilon \sim N(0, \sigma^2 I))$$

Vemo, da ima  $\tau$  poln rang, torej sledi:

$$\hat{\beta}(X) = (\tau^T \tau)^{-1} \tau^T X \sim N(\beta, \sigma^2 (\tau^T \tau)^{-1})$$

$$\hat{\sigma}^2(X) = \frac{1}{n-d} VKR = \frac{1}{n-d} \|X - \hat{\beta}\|^2, \text{ kjer je } \frac{\|X - \hat{\beta}\|^2}{\sigma^2} = \frac{\|X - \tau\hat{\beta}\|^2}{\sigma^2} \sim \chi_{n-d}^2$$

Dalje sta  $\tau^T X$  in  $VKR(X)$  neodvisni (torej tudi  $\hat{\beta}(X)$  in  $VKR(X)$  neodvisni)

$$\text{Standardiziramo } \hat{\beta}: \frac{1}{\sigma} \sqrt{\tau^T \tau} (\hat{\beta}(X) - \beta) \sim N(0, I_{d \times d})$$

$$\text{in sledi: } \left\| \frac{1}{\sigma} \sqrt{\tau^T \tau} (\hat{\beta}(X) - \beta) \right\|^2 \sim \chi_d^2$$

$$\text{Vedi: } F(X; \beta) = \frac{\frac{1}{\sigma^2} \langle \sqrt{\tau^T \tau} (\hat{\beta}(X) - \beta), \sqrt{\tau^T \tau} (\hat{\beta}(X) - \beta) \rangle / d}{\frac{1}{\sigma^2} \|X - \tau\hat{\beta}\|^2 / (n-d)} \sim \frac{\frac{\chi_d^2}{d}}{\frac{\chi_{n-d}^2}{n-d}}$$

Vemo namreč, da če sta  $H \sim \chi_h^2$  in  $K \sim \chi_k^2$  neodv. ima  $\frac{H/h}{K/k}$  porazdelitev  $F_{h,k}$

$$\text{Vedi torej } F(X; \beta) = \frac{\langle \sqrt{\tau^T \tau} (\hat{\beta}(X) - \beta), \sqrt{\tau^T \tau} (\hat{\beta}(X) - \beta) \rangle / d}{\|X - \tau\hat{\beta}\|^2 / (n-d)} \sim F_{d, n-d, \alpha}$$

Ustavimo  $D = [0, F_{d, n-d, \alpha}]$ . Sedaj je  $P(F_{d, n-d} \in D) = 1 - \alpha$ .

Priznansko območje razpaja je  $C(X) = \{\beta \mid F(X; \beta) \leq F_{d, n-d, \alpha}\}$

Diagonaliziramo  $\tau^T \tau = Q \cdot \Lambda \cdot Q^T$ , kjer je  $Q \in O(d)$  ortogonalna in  $\Lambda$  diagonalna z  $\lambda_i > 0$ .

$$\text{Vedi: } \langle (\tau^T \tau) (\hat{\beta} - \beta), \hat{\beta} - \beta \rangle = \langle \Lambda Q^T (\hat{\beta} - \beta), Q^T (\hat{\beta} - \beta) \rangle$$

$$\text{Rečujemo } \langle \Lambda Q^T (\hat{\beta} - \beta), Q^T (\hat{\beta} - \beta) \rangle \leq \frac{d}{n-d} VKR \cdot F_{d, n-d, \alpha} =: \eta^2 = \eta^2(X)$$

Rešitev ~~ko~~ območje razpaja, je elipsoid:

$$C(X) = \left\{ \hat{\beta} + Q \cdot \begin{bmatrix} \frac{\eta}{\sqrt{\lambda_1}} \cdot u_1 \\ \vdots \\ \frac{\eta}{\sqrt{\lambda_d}} \cdot u_d \end{bmatrix} \mid u_1^2 + \dots + u_d^2 \leq \eta^2 \right\}$$

Kaj je torej treba narediti?

- diagonaliziramo  $\tau^T \tau = Q \cdot \Lambda \cdot Q^T$ , kjer je  $Q$  ~~ortogonalna~~ <sup>matrika</sup> lastnih ~~vrednosti~~ <sup>vektorjev</sup>  $\tau^T \tau$ ,  
in  $\Lambda$  diagonalna matrika z  $\lambda_i > 0$ , ki so lastne vrednosti  $\tau^T \tau$ , na diagonali.

-  $\eta^2$  računamo po formuli  $\eta = \frac{d}{n-d} \cdot VKR \cdot F_{d, n-d, \alpha}$

Poračunamo  $\mathbf{V}$  in  $\mathbf{Q}$  in dolimo:

$$\lambda_1 = 15739.25 \quad \lambda_2 = 368.3234 \quad \lambda_3 = 118.1484 \quad \eta^2 = 2.057032$$

$$\mathbf{Q} = \text{matrica last. vekt.} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3] = \begin{bmatrix} 0.9340480 & -0.2341740 & 0.2696606 \\ 0.1982784 & -0.2879862 & -0.9368824 \\ 0.2970521 & 0.9285615 & -0.225613 \end{bmatrix}$$

Dolimo torej območje zaupanja, ki je elipsoid:


$$\mathbf{B} \in \left\{ \hat{\mathbf{B}} + \mathbf{Q} \begin{bmatrix} \frac{1}{\sqrt{\lambda_1}} u_1 \\ \frac{1}{\sqrt{\lambda_2}} u_2 \\ \frac{1}{\sqrt{\lambda_3}} u_3 \end{bmatrix} \mid u_1^2 + u_2^2 + u_3^2 \leq \eta^2 \right\}$$

→ polarni  $\frac{1}{\sqrt{\lambda_1}}, \frac{1}{\sqrt{\lambda_2}}, \frac{1}{\sqrt{\lambda_3}}$  na stolpcih matrice  $\mathbf{Q}$ .

To je torej elipsoid v koordinatnem sistemu

$\mathbf{v}_1 \times \mathbf{v}_2 \times \mathbf{v}_3$  v predstavitvi  $\mathbf{B}$  in z polarnimi dolžinami:

$$\begin{aligned} a &= \frac{1}{\sqrt{\lambda_1}} = 0.01639642 & a &= \sqrt{\frac{\eta^2}{\lambda_1}} = 0.01143216 \\ b &= \frac{1}{\sqrt{\lambda_2}} = 0.1071831 & b &= \sqrt{\frac{\eta^2}{\lambda_2}} = 0.07473186 \\ c &= \frac{1}{\sqrt{\lambda_3}} = 0.1892461 & c &= \sqrt{\frac{\eta^2}{\lambda_3}} = 0.1319491 \end{aligned}$$



Ker zleka pove več kot 1000 besed sem raje območje zaupanja napisal v programu R kot 3D diagram. Koda za 3D diagrama je v R datoteki `exp.R` in je tu ne bom natančneje opisoval.

(iv) Vlekatni intervali zaupanja za  $\beta_1, \beta_2, \beta_3$  z Bonferronijevim popravlkom,

Repredstavljamo: Ker  $\hat{\mathbf{B}} \sim N(\mathbf{B}, \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}) \Rightarrow \hat{\beta}_j \sim N(\beta_j, \sigma^2 (\mathbf{Z}^T \mathbf{Z})_{jj}^{-1})$

Vedi

$$t_{m-d} \sim \frac{\frac{\hat{\beta}_j - \beta_j}{\sigma \sqrt{(\mathbf{Z}^T \mathbf{Z})_{jj}^{-1}}}}{\sqrt{\frac{1}{\sigma^2} \|\mathbf{X} - \mathbf{Z} \hat{\mathbf{B}}\|^2 / (m-d)}}$$

kar je pivotna funkcija za  $e(\mathbf{B}, \sigma^2) = \mathbf{B}$ .

Če vramemo  $D = [-t_{m-d; \alpha/2}, t_{m-d; \alpha/2}]$  dolimo interval zaupanja:

$$\left[ \hat{\beta}_j - t_{m-d; \alpha/2} \cdot \sqrt{\frac{(\mathbf{Z}^T \mathbf{Z})_{jj}^{-1} \|\mathbf{X} - \mathbf{Z} \hat{\mathbf{B}}\|^2}{m-d}}, \hat{\beta}_j + t_{m-d; \alpha/2} \cdot \sqrt{\frac{(\mathbf{Z}^T \mathbf{Z})_{jj}^{-1} \|\mathbf{X} - \mathbf{Z} \hat{\mathbf{B}}\|^2}{m-d}} \right]$$

Da dolimo območje zaupanja iz intervalov zaupanja za posamezen  $\beta_j$  lahko po Bonferroniju zamenjamo  $\alpha$  s prirajeno  $\frac{\alpha}{d}$  ( $d=3$  pri nas).

Ustvarimo dobjenih 1.7. s Kartezijem produktom sestavimo območje zaupanja.



Poračunamo v R in dolimo:

$$\hat{\beta}_j \pm \underbrace{t_{n-d; \frac{\alpha}{2d}} \cdot \sqrt{\frac{(r^2 e_{jj})}{(n-d)} \cdot VKR}}_{\text{"meja"}}$$

l.č. za  $\beta_1$ :  $[0.8603245, 0.9306539]$

l.č. za  $\beta_2$ :  $[-0.9031617, -0.6882240]$

l.č. za  $\beta_3$ :  $[-0.3209717, -0.1917910]$

Tudi to območje zaupanja sem narisal v R, vendar ni zelo aktualno, saj gre le za kvader.

Uglavljaje pa je obe območji zaupanja primerjati po volumnu - tisto, ki bo imelo manjši volumen je torej bolj natančno in sorodnično boljše.

Poračunamo:

$$V(\text{elipsoid}) = \frac{4}{3} \cdot \pi \cdot a \cdot b \cdot c = 0.0013937 = 0.0004722037$$

~~V(Bonferronijev kvader)~~

$$V(\text{Bonferronijev kvader}) = d(171) \cdot d(172) \cdot d(173) = 0.0019528$$

( $d(\cdot)$  je dolžina pripadajočega intervala zaupanja).

Volumen elipsoida je ~~ta~~ <sup>precej</sup> manjši, kar pomeni da je to o.č. bolj natančno.